

Ottimizzazione della *Sentiment Analysis* su Twitter: vettorializzazione TF-IDF, pragmatica dell'interpunzione e mitigazione del *Topic Bias*

Matteo Curiale – Matricola: 0286457

Sommario

La *Sentiment Analysis* applicata ai testi brevi generati da utenti su internet, come i tweet, presenta peculiarità e difficoltà specifiche, principalmente dovute alla brevità dei testi, all'abbondanza di ironia e al forte rumore. Questo studio propone una *pipeline* ibrida che integra regole linguistiche deterministiche e modelli di *Machine Learning* lineari per cercare di ottimizzare i tradizionali approcci *Bag-of-Words*. Utilizzando il corpus EVALITA SENTIPOLC 2016, è stato implementato un sistema di *Dependency Parsing*, tramite Stanza per propagare la negazione sintattica, affiancato da un modulo di *data cleaning* avanzato. Attraverso test incrociati, lo studio dimostra l'esistenza di un fisiologico *Topic Bias*, dovuto alla tipologia di database raccolto, il quale è stato mitigato tramite *Feature Engineering* e l'esclusione di entità politiche e mediatiche. Inoltre, i risultati indicano che preservare l'interpunzione emotiva (nello specifico punto esclamativo e punto interrogativo) e neutralizzare il rumore di dominio permette a un classificatore di Regressione Logistica con vettorializzazione TF-IDF di raggiungere una F1-Macro di 0.7188, riducendo i Falsi Positivi derivanti dal carattere ironico di alcuni tweet, grazie all'applicazione del *Threshold Moving*.

1 Introduzione

L'analisi automatica del sentiment sui social media è un campo di ricerca in continua evoluzione. Nello specifico, il micro-blogging su piattaforme come Twitter è caratterizzato da una sintassi peculiare: i testi sono brevi, frammentati, ricchi di espressioni gergali, *hashtag* e interpunzione utilizzata spesso per fini pragmatici ed espressivi.

Gli approcci statistici dei vettorializzatori tradizionali, basati sulla frequenza dei termini, non riescono a ben catturare il significato affettivo, specialmente in questi contesti, in quanto il limite principale risiede nell'incapacità di queste architetture di catturare lo specifico contesto frasale; da qui deriva, ad esempio, l'impossibilità di avere contezza di inversioni semantiche dovute alla negazione. Inoltre, quest'ultimo fenomeno, noto come *Shortcut Learning*, porta i modelli ad associare la polarità negativa o positiva a specifiche entità neutre, come nomi di personaggi politici, piuttosto che alla struttura linguistica e agli elementi della frase, generando un *Topic Bias*.

Il presente studio si pone l'obiettivo di affrontare queste limitazioni, cercando di controllare rigorosamente il dato linguistico a monte, più che la parte statistica a valle. Nello specifico, vengono integrati alberi di dipendenza sintattica per la gestione della negazione.

Le principali domande di ricerca sono: 1) In che misura l'applicazione di filtri dominio-specifici riduce il *Topic Bias*? 2) Qual è l'impatto della punteggiatura emotiva e della propagazione della negazione sintattica sulle performance dei classificatori lineari?

2 Stato dell'Arte

La letteratura sulla *Sentiment Analysis* ha subito un'evoluzione significativa nell'ultimo decennio, transitando da approcci basati su dizionari lessicali a modelli di *Deep Learning*.

- **Approcci Lessicali:** I primi studi si sono basati sull'utilizzo di dizionari di polarità aprioristici (es. *SentiWordNet*). Tuttavia, tali metodi fallivano nel catturare il contesto, trattando le parole come entità isolate e ignorando costrutti come l'ironia o la negazione.
- **Modelli Supervisionati Classici:** Grazie a dataset annotati come SENTIPOLC (Barbieri et al., 2016), la ricerca si è spostata su modelli statistici come Naive Bayes. Questi sistemi, basati sulla frequenza dei termini (*Bag-of-Words*), sono stati molto diffusi, grazie alla loro efficienza computazionale.
- **Deep Learning e Transformer:** La frontiera attuale è rappresentata dai *Large Language Models* (ma cfr. Bender et al., 2021). Tali architetture, basate sul meccanismo di *self-attention*, superano i limiti dei modelli statistici tradizionali poiché codificano il contesto globale di ogni token.

Il presente lavoro si colloca nel solco degli approcci supervisionati classici, esplorando come la riduzione del rumore e la corretta modellazione sintattica possano ottimizzare i modelli.

3 Quadro Teorico

3.1 La Classificazione del Testo

La *Sentiment Analysis* è qui formalizzata come un *task* di classificazione binaria, dove la classe 0 indica una polarità negativa e la classe 1 una polarità positiva. L'approccio adottato è supervisionato e si basa sull'apprendimento di pesi statistici a partire da un corpus etichettato.

3.2 Metodologie Algoritmiche

Per la fase sperimentale sono stati confrontati due classificatori:

Naive Bayes (NB): Modello probabilistico che stima la probabilità di una classe c dato un documento d utilizzando il teorema di Bayes, assumendo l'indipendenza condizionale delle *feature*:

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)} \quad (1)$$

La stima della classe si riduce a:

$$P(c|d) \propto P(c) \prod_{i=1}^n P(w_i|c) \quad (2)$$

Regressione Logistica (LR): Modello lineare discriminativo che stima la probabilità di appartenenza alla classe y dato un vettore di input x , tramite la funzione sigmoide σ :

$$P(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (3)$$

Dove w rappresenta il vettore dei pesi apprendibili e b il bias. L'ottimizzazione avviene minimizzando la funzione di costo logaritmica (*Log-Loss*).

3.3 Vettorializzazione: Bag-of-Words e TF-IDF

Per convertire il testo in un vettore processabile dai classificatori, il vettorializzatore più basilare è il *Bag-of-Words* (BoW), il quale rappresenta un documento testuale come un insieme disordinato dei suoi termini. Con ciò, ignora l'ordine sintattico e la grammatica e registra esclusivamente la frequenza assoluta di ciascuna parola del vocabolario, desunto dalla totalità dei documenti del corpus, all'interno del testo. Ne consegue che il BoW finisca per dare un peso sproporzionato a parole globalmente frequenti ma semanticamente neutre, limitando il potere predittivo dei termini più rari.

Come superamento di questo approccio, si è fatto ricorso alla vettorializzazione TF-IDF (*Term Frequency-Inverse Document Frequency*), la quale assegna un peso a ogni termine calcolando il prodotto tra la frequenza del termine nel documento (*TF*) e il

logaritmo inverso della sua frequenza nell'intero corpus (*IDF*). Come consolidato nell'*Information Retrieval* (Manning, Raghavan & Schütze, 2008), questo paradigma associa un peso minore alle parole troppo diffuse, e quindi meno caratterizzanti una o l'altra classe specifica, e un peso maggiore ai termini rari, per cui più decisamente discriminativi.

4 Dati e Metodi

4.1 Il Corpus di Riferimento

I dati utilizzati derivano dal dataset SENTIPOLC, rilasciato per la campagna EVALITA 2016 (Barbieri et al., 2016). Per addestrare il classificatore binario, sono stati isolati solamente i tweet presentanti una polarità netta (etichette *opos* e *oneg* divergenti), scartando quindi i testi neutri o misti.

4.2 Pre-processing e Lexical Normalization

La *pipeline* di *pre-processing* è così configurata:

- **Traduzione Semantica:** Conversione delle *emoji*, tramite l'utilizzo della libreria *Python emoji*, in stringhe testuali descrittive (es. `:cuore_rosso:`).
- **Pulizia degli Artefatti:** Rimozione dei tag tipici del dataset, come `<URL>`, `<MENTION_\d+>`, e marcatori di *retweet* (RT).
- **Normalizzazione degli Hashtag:** Tramite espressione regolare, è stato conservato il blocco testuale degli *hashtag*, apponendo il prefisso tag `htag_` (es. `htag_litalia`). L'eventuale apostrofo viene eliminato e le parti testuali vengono saldate.

4.3 Estrazione Sintattica con Stanza

Per limitare la cecità sintattica dei vettorializzatori di fronte alle negazioni, le quali è utile considerare, in quanto possono dare origine a un *Sentiment Shift*, è stato integrato un modulo di *Dependency Parsing* basato sulla libreria neurale *Stanza* (Qi et al., 2020). Come vocabolario sono stati selezionati 9 lemmi di negazione, estratti dalle risorse lessicali del progetto europeo OpeNER. Navigando l'albero delle dipendenze, l'algoritmo individua tali lemmi e propaga deterministicamente il suffisso `_NEG` alla radice sintattica negata (*head*) e ai suoi dipendenti diretti (*obj*, *xcomp*, *conj*).

4.4 Topic Bias

Esperimenti preliminari hanno evidenziato la propensione dei classificatori lineari a memorizzare entità politiche molto polarizzate e polarizzanti nel panorama

del 2016 (es. *Grillo, PD*). Per impedire al modello di applicare meccanismi di *shortcut learning*, ossia classificare solamente sulla base del *sentiment* associato generalmente a un soggetto politico, e per spingerlo a fare riferimento ad altri elementi lessicali, è stato implementato un esaustivo filtro basato su *stopwords di dominio*.

4.5 Punteggiatura Emotiva

Durante la fase di pulizia del testo, sono stati conservati i punti interrogativi ed esclamativi (?, !), in quanto i test esplorativi hanno dimostrato un potere discriminativo fra le classi.

4.6 Setup Sperimentale

L'architettura è stata ottimizzata tramite una *Grid Search* con validazione incrociata ($k = 5$) sul *Training Set*, grazie alla libreria **scikit-learn** (Pedregosa et al., 2011). Lo spazio di ricerca ha valutato sia combinazioni di vettorizzatori (BoW, TF-IDF) che algoritmi classificatori (NB, LR), cercando di massimizzare la *F1 Macro*, attraverso la calibrazione della forza di regolarizzazione C , delle soglie minime di frequenza (*min_df*) e della grandezza degli *n-grammi*.

5 Risultati

5.1 Selezione del Modello

L'architettura che si è dimostrata sperimentalmente superiore si è rivelata la Regressione Logistica associata alla vettorizzazione TF-IDF. Il modello presenta una penalità L_2 (Ridge) con forza di regolarizzazione $C = 5.0$: ciò dimostra che le *feature* estratte post-pulizia sono molto informative. Lo spazio vettoriale, configurato su unigrammi e bigrammi con un tetto limite di 5.000 dimensioni, ha garantito una metrica **F1-Macro** di validazione pari **0.7188**.

5.2 Valutazione sul Test Set e Threshold Moving

In fase di predizione sul Test Set (1.050 campioni), il classificatore ha ottenuto un'**Accuratezza globale del 72%**, raggiunta grazie anche a una calibrazione della soglia decisionale (*Threshold Moving*) al **70%**, rispetto al valore di default al 50%, al fine di mitigare i Falsi Positivi dovuti alla presenza di ironia all'interno di alcuni testi.

Tabella 1: Matrice di Confusione (Soglia 0.70)

	Predetto Neg.	Predetto Pos.
Reale Neg.	626 (TN)	108 (FP)
Reale Pos.	183 (FN)	133 (TP)

Tabella 2: Report di Classificazione (Soglia 0.70)

	Prec.	Rec.	F1	Supp.
Cl. 0 (Neg.)	0.77	0.85	0.81	734
Cl. 1 (Pos.)	0.55	0.42	0.48	316
Accuracy			0.72	1050
Macro Avg	0.66	0.64	0.64	1050
Weighted Avg	0.71	0.72	0.71	1050

Come si desume dalle tabelle 1 e 2, tale calibrazione ha sacrificato parzialmente la *Recall* della classe positiva a favore di una massimizzazione della *Precision* e una minimizzazione dei Falsi Positivi.

6 Discussione

In merito alla classe negativa, l'estrazione della *Feature Importance* post-addestramento ha dimostrato empiricamente le ipotesi linguistiche di partenza. I tre coefficienti di maggior peso abbracciano tre distinti livelli dell'analisi linguistica:

1. **Semantico:** Il termine neutro *problema* (peso: -4.39) si afferma come il predittore di negatività, confermando l'efficacia della rimozione del *Topic Bias*.
2. **Lessicale:** L'imprecazione *merda* (peso: -3.91) opera come marcatore esplicito.
3. **Pragmatico:** Il punto interrogativo ? (peso: -3.17) si manifesta come uno degli strumenti primari per veicolare lamentele o disillusione.

6.1 Falsi Positivi e Ironia

Un'ispezione mirata (*Error Analysis*) ha permesso di quantificare l'impatto dell'ironia sui Falsi Positivi. I dati rivelano che il 33.3% dei tweet erroneamente classificati come positivi (FP) è caratterizzato da intenti ironici. Dal confronto con il gruppo di controllo (Veri Negativi), che presenta una densità di tweet ironici del 28.4%, si desume che l'ironia agisca da fattore di disturbo per l'algoritmo. Di fatto, questo aspetto pragmatico inganna il classificatore lineare, inducendolo ad assegnare punteggi positivi a un lessico che risulta apparentemente elogiativo.

6.2 Efficacia delle Stopwords di dominio

L'esperimento dimostra che affidarsi a sole librerie generaliste di *stopwords* risulta poco efficiente in contesti molto polarizzati e che il potere predittivo del modello, specialmente tradizionale, dipende fortemente dalla consapevolezza dominio-specifica.

7 Limiti dello Studio

- **Binarità del *Sentiment*:** La dicotomia della classificazione binaria rappresenta una forzatura pragmatica. L'assenza della componente “neutrale”, il *task* si allontana in parte dalla piena applicabilità reale.
- **Limite temporale:** Il corpus SENTIPOLC 2016 campiona un gergo in parte sorpassato, per cui è ragionevole inferire che il modello subirebbe un inevitabile calo prestazionale se applicato ai testi odierni.
- **Rigidità strutturale di vettorializzatori e classificatori:** Nonostante l'integrazione di *Stanza* abbia integrato informazioni sintattiche, utili alla propagazione della negazione locale, i due vettorializzatori rimangono contestualmente ignari. Fenomeni sintattici complessi e dipendenze a lunga distanza rimangono inaccessibili.

8 Conclusioni e Sviluppi Futuri

Il presente studio dimostra che un'architettura linguistica solida e mirata possa ottimizzare modelli classici in complessi task come la *Sentiment Analysis*. L'impiego di alberi di dipendenza sintattica e di strumenti di riduzione del *Topic Bias* ha generato un classificatore lineare con buone prestazioni, al netto della specificità del dominio d'applicazione e dei limiti strutturali degli strumenti algoritmici.

La naturale transizione è verso architetture più moderne che sfruttino il meccanismo della *self-attention* (quali il Transformer ALBERTo), in grado di modellare il contesto profondo anche di testi rumorosi e molto variabili come quelli prodotti su Twitter, mitigando così l'influsso dell'ironia sulla classificazione.

Riferimenti bibliografici

- [1] Agerri, R., Bermudez, J., & Rigau, G. (2013). *OpeNER: Open Polarity Enhanced Named Entity Recognition for European Languages*. Proceedings of the 10th Horizon 2020.
- [2] Barbieri, F., Basile, V., Croce, D., Nissim, M., Novielli, N., & Patti, V. (2016). *Overview of the EVALITA 2016 SENTiment POLarity Classification Task*. Proceedings of EVALITA 2016.
- [3] Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). *On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?* Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 610–623.
- [4] Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- [5] Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [6] Polignano, M., Basile, P., de Gemmis, M., Semeraro, G., & Basile, V. (2019). *ALBERTo: Italian BERT Language Understanding Model for NLP Challenging Tasks Based on Tweets*. Proceedings of the 6th Italian Conference on Computational Linguistics (CLiC-it).
- [7] Qi, P., Zhang, Y., Zhang, Y., Bolton, J., & Manning, C. D. (2020). *Stanza: A Python Natural Language Processing Toolkit for Many Human Languages*. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics.